aprende tidyverse

Es super importante la interacción durante la clase

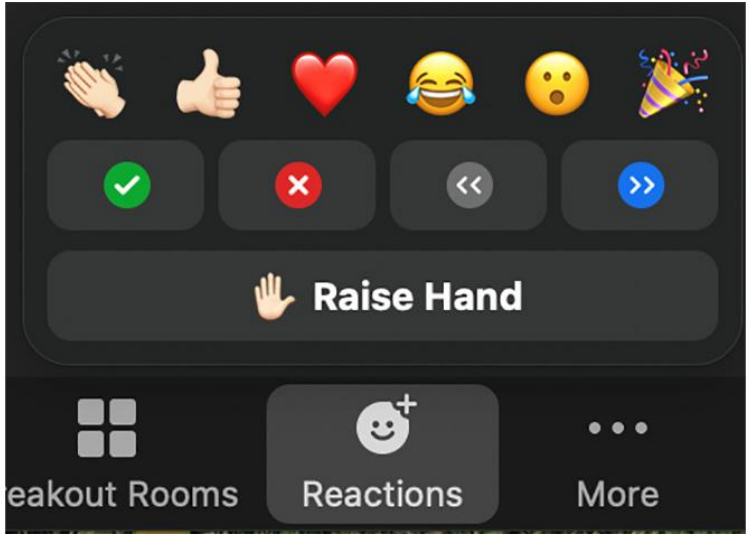

Mantener microfono y camara apagados durante la clase, excepto para hacer preguntas, por favor antes levantar la mano ✋.

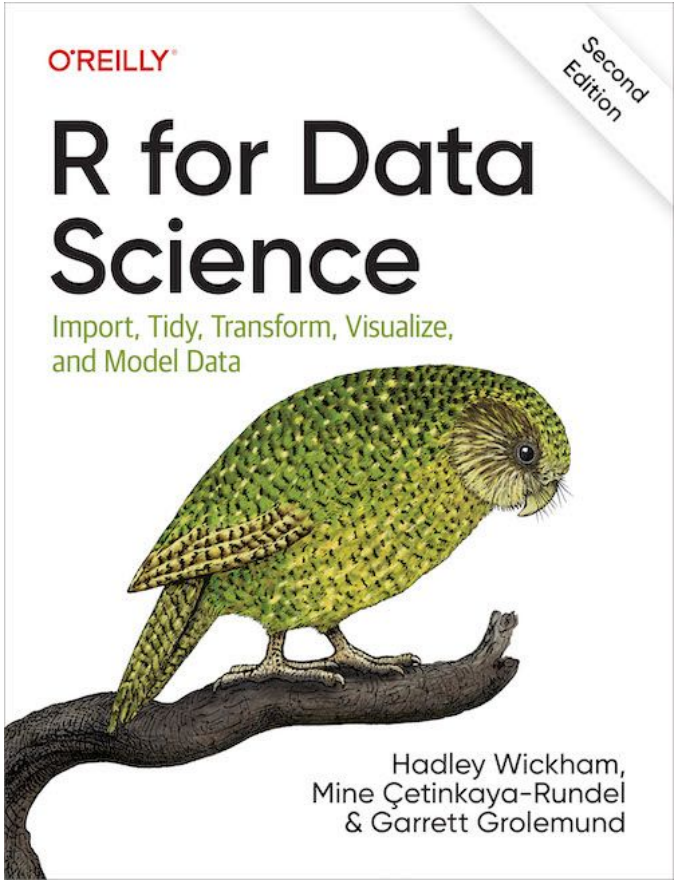

https://r4ds.hadley.nz/

Este es un curso de programación en R

- **Lectura, limpieza y exploración de datos**
- **Visualización de datos**
- ***Programación Funcional***

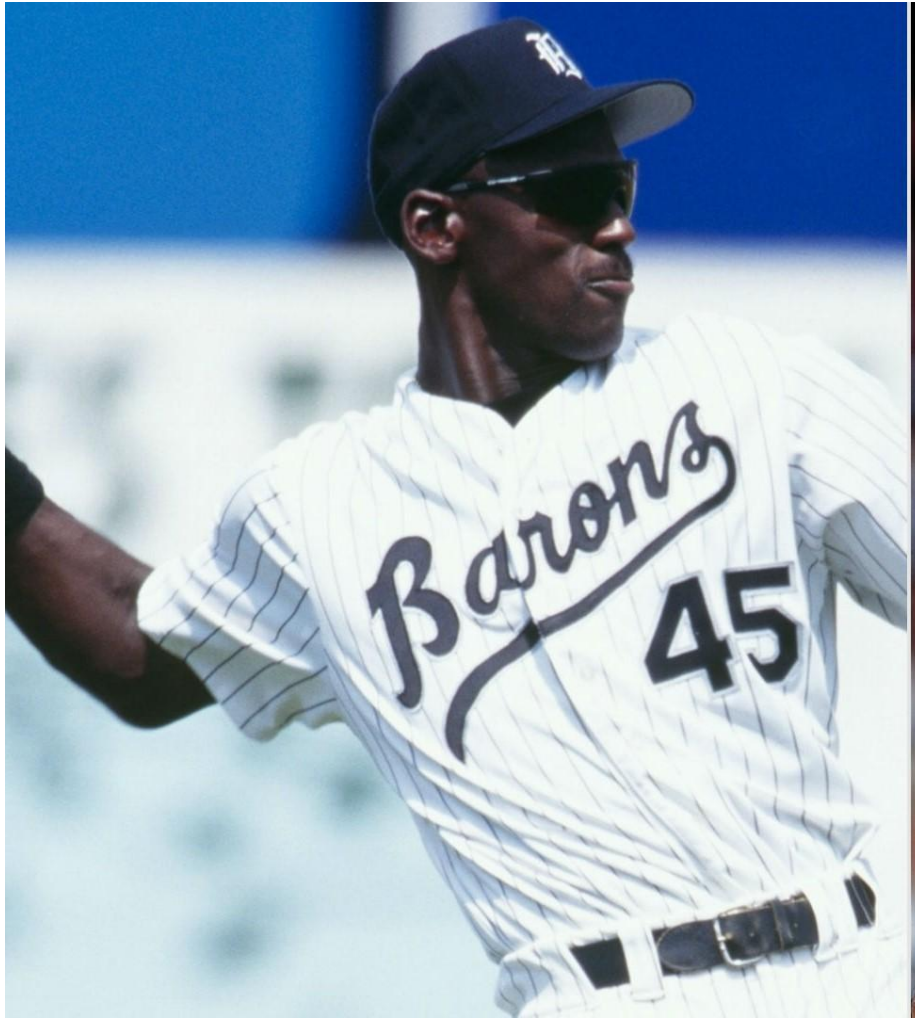
Barons
45

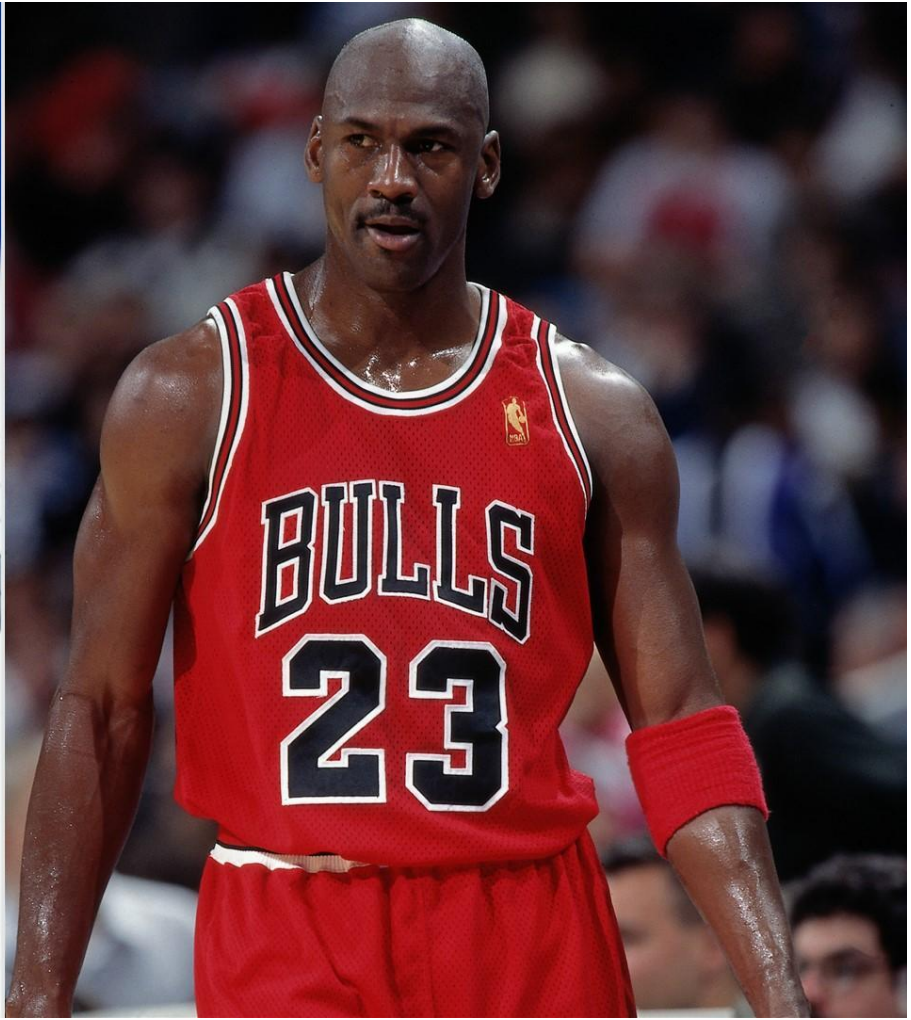
BULLS
23

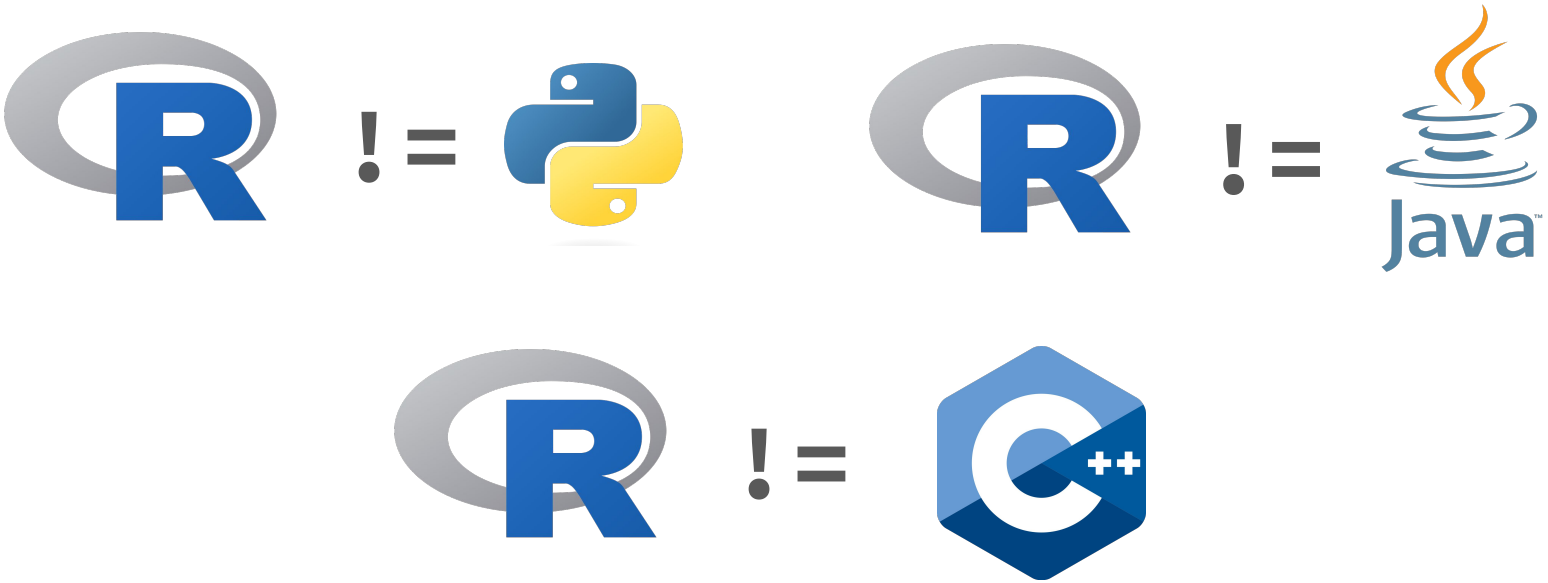
R
!=
R
!=
Java
R
!=
C++

Programación Funcional

julia

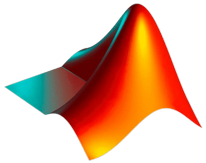

MATLAB®

Esto es una buena noticia, R es mucho más sencillo de entender que otros lenguajes.

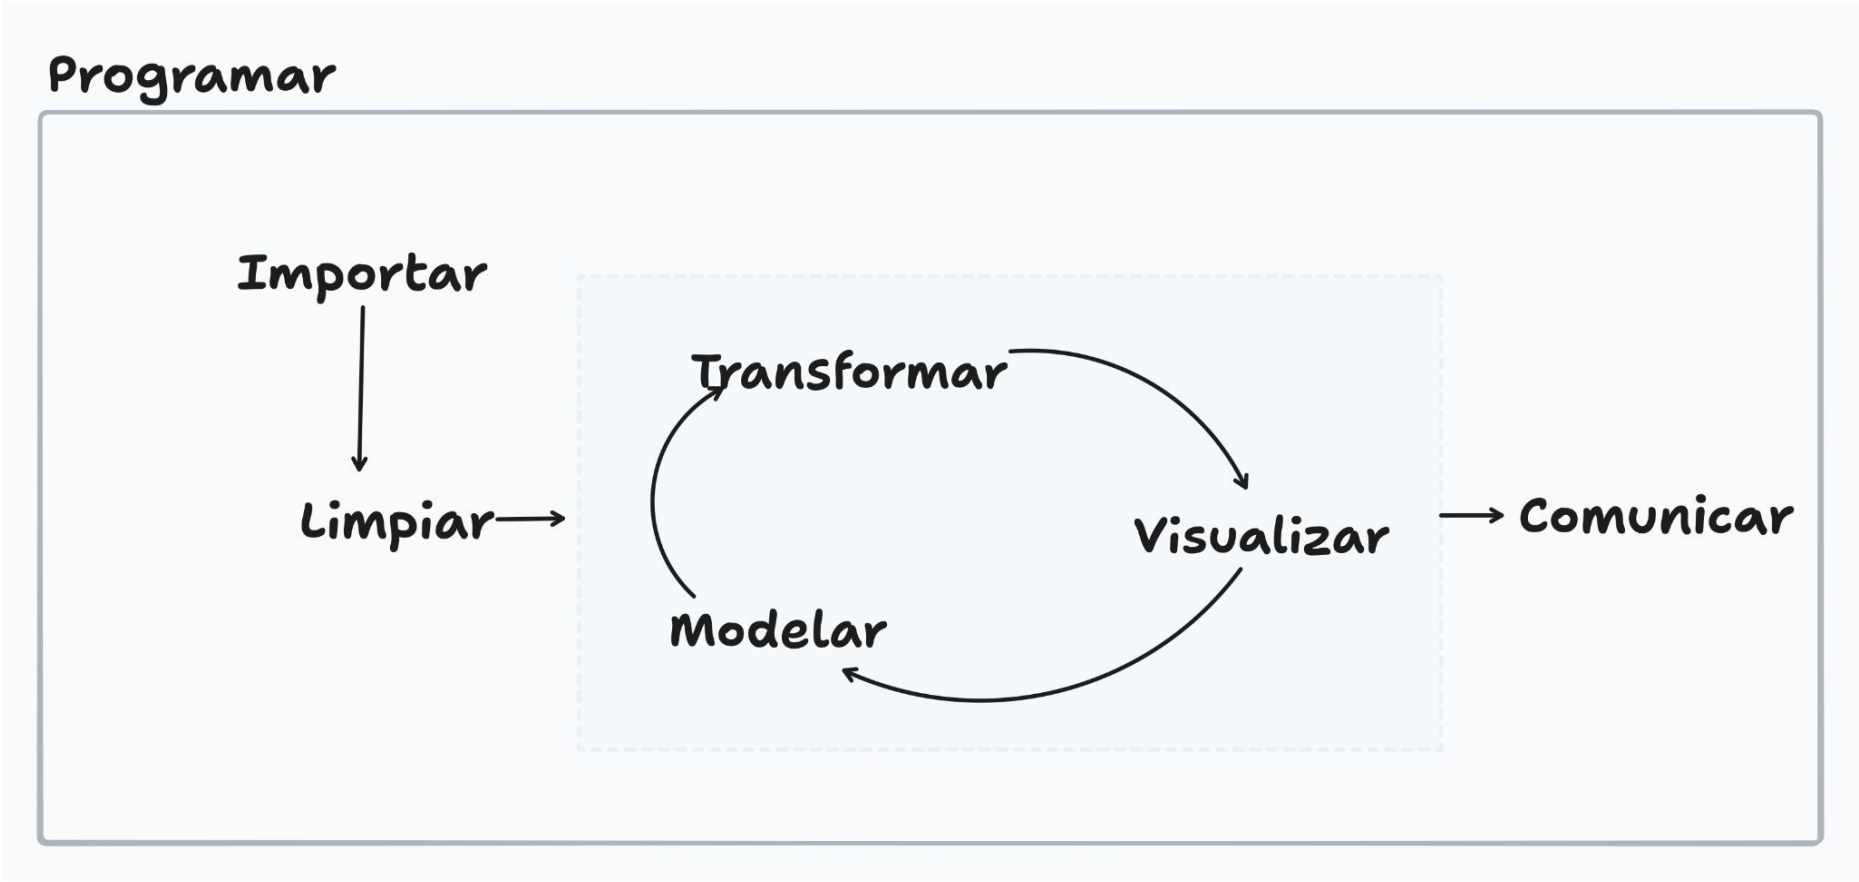
Programar
Importar
Limpiar
Transformar
Visualizar
Modelar
Comunicar

El 50% del trabajo es encontrar las herramientas correctas

Tidyverse

Un lenguaje para abordar retos de ciencia de datos con código R. Su meta principal es hacer más fácil la conversación entre una persona y un conjunto de datos. Buscamos crear una situación en la que, siguiendo el camino más sencillo, naturalmente se llegue a resultados exitosos.

https://design.tidyverse.org/unifying.html

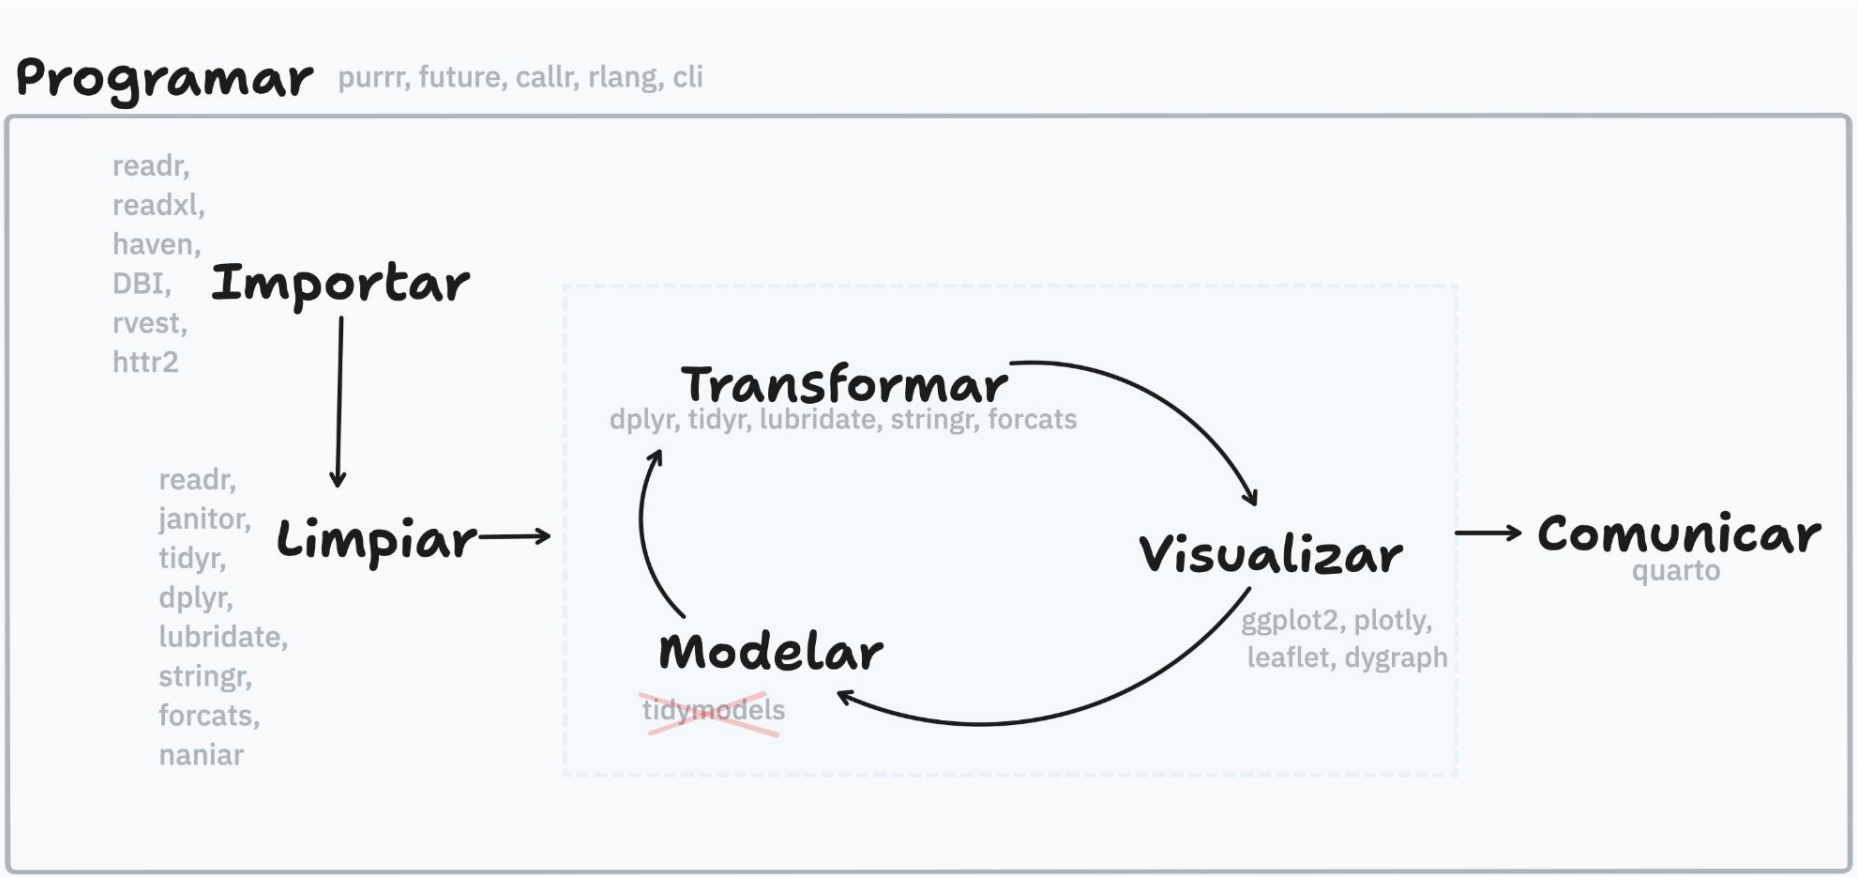
Programar
purrr, future, callr, rlang, cli
readr,
readxl,
haven,
DBI,
rvest,
httr2
Importar
readr,
janitor,
tidyr,
dplyr,
lubridate,
stringr,
forcats,
naniar
Limpiar
Transformar
dplyr, tidyr, lubridate, stringr, forcats
Visualizar
ggplot2, plotly,
leaflet, dygraph
Modelar
tidymodels
Comunicar
quarto

Temario de la semana 1

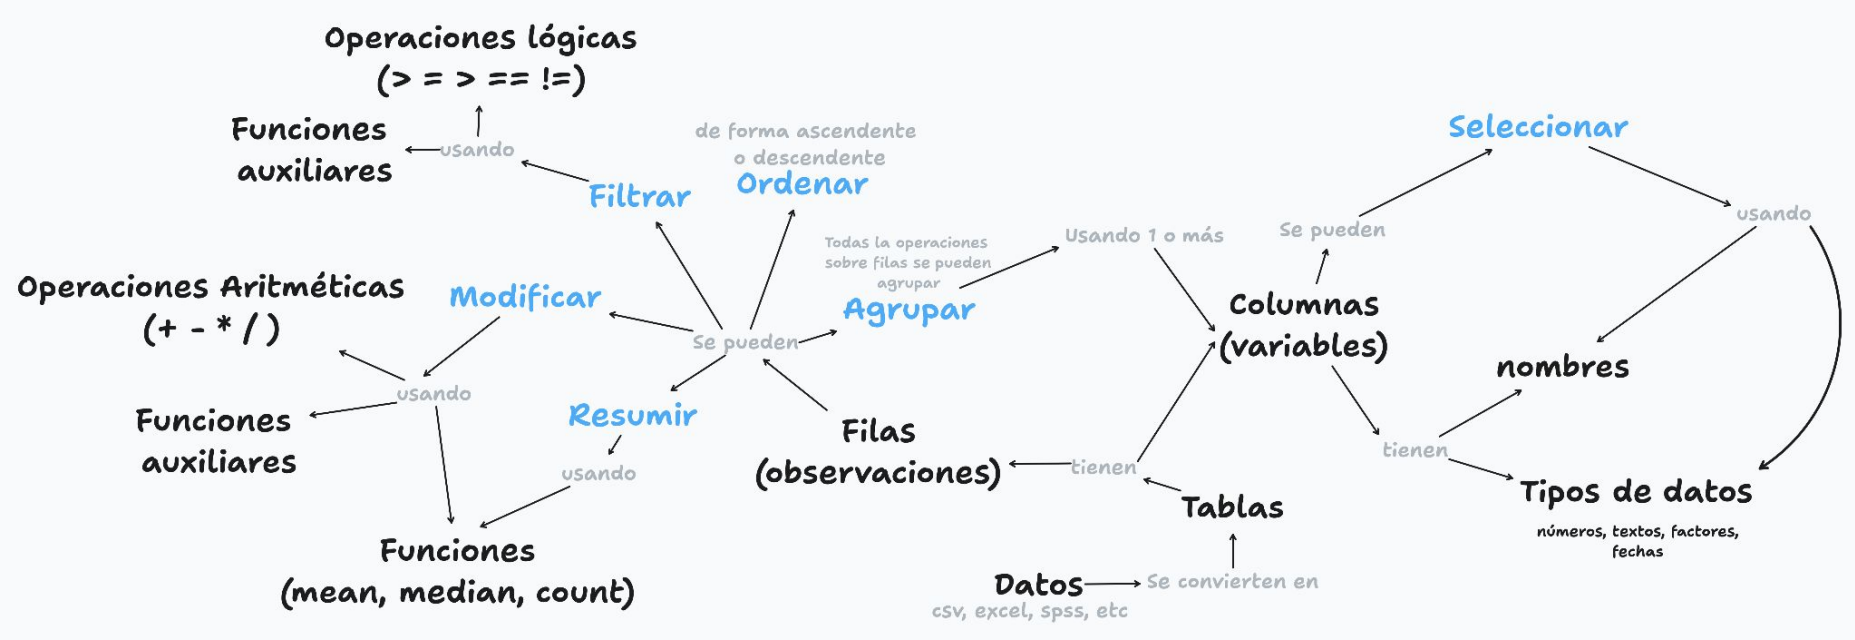
Operaciones lógicas
(> = > == !=)
Funciones
auxiliares
usando
Filtrar
de forma ascendente
o descendente
Ordenar
Seleccionar
usando
Se pueden
Todas la operaciones
sobre filas se pueden
agrupar
Usando 1 o más
Agrupar
Columnas
(variables)
Operaciones Aritméticas
(+ - * /)
Modificar
Se pueden
usando
Funciones
auxiliares
Resumir
usando
Funciones
(mean, median, count)
Filas
(observaciones)
tienen
Tablas
Datos
csv, excel, spss, etc
Se convierten en
nombres
tienen
Tipos de datos
números, textos, factores,
fechas

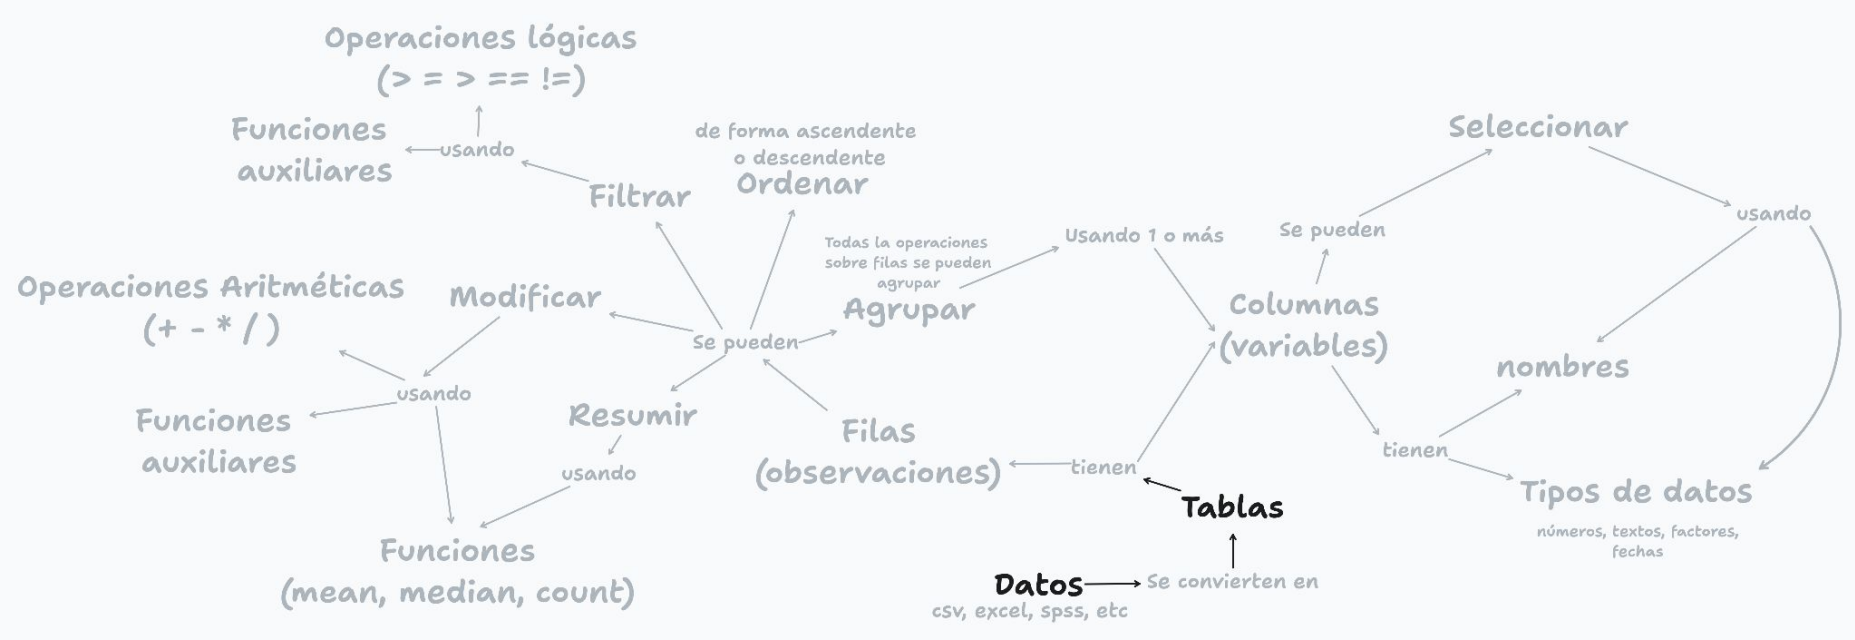
Operaciones lógicas
(> = > == !=)
Funciones
auxiliares
usando
Filtrar
de forma ascendente
o descendente
Ordenar
Seleccionar
usando
Se pueden
Todas la operaciones
sobre filas se pueden
agrupar
Usando 1 o más
Agrupar
Columnas
(variables)
Operaciones Aritméticas
(+ - * /)
Modificar
Se pueden
nombres
usando
Funciones
auxiliares
Resumir
Filas
(observaciones)
tienen
tienen
usando
Tipos de datos
números, textos, factores,
fechas
Tablas
Funciones
(mean, median, count)
Datos
csv, excel, spss, etc
Se convierten en

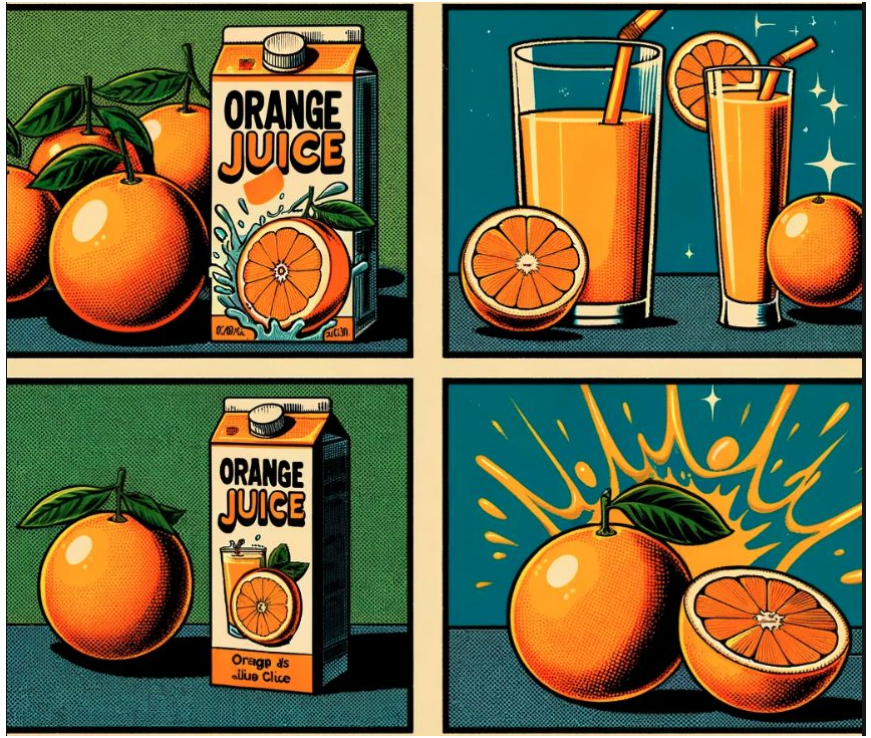

Los datos pueden venir en diferentes presentaciones

- CSV
- Excel
- SPSS
- Bases de datos
- APIs

```r
datos <- read_csv("ruta del archivo")
```

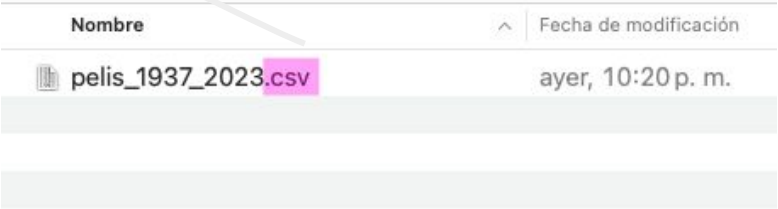

Esto va a ser una constante para la mayoría de tipos de datos

```r
datos <- read_csv("ruta del archivo")
datos <- read_xlsx("ruta del archivo")
datos <- read_sav("ruta del archivo")
```

Ruta
(dirección del archivo en mi computadora)

Nombre de la tabla
(el que nosotros queramos)

```
datos <- read_csv("ruta del archivo")
```

Función de lectura de datos
(para archivos csv)

Nombre de la tabla
(el que nosotros queramos)

Ruta
(dirección del archivo
en mi computadora)

```
datos <- read_csv("C:\Users\martita\Documents\datos\pelis.csv")
```

**Función de
lectura de datos**
(para archivos csv)

Columnas →

Filas ↓

titulo	mpa	genero	duracion	fecha_estreno
Star Wars	PG	Adventure	121	1977-05-25
Smokey and the Bandit	PG	Action	96	1977-05-26
Close Encounters of the Third Kind	PG	Science Fiction	135	1977-12-14
Saturday Night Fever	R	Music	119	1977-12-16
A Bridge Too Far	PG	Drama	175	1977-06-15
The Deep	PG	Mystery	123	1977-06-17

Nombres de columnas

titulo	mpa	genero	duracion	fecha_estreno
Star Wars	PG	Adventure	121	1977-05-25
Smokey and the Bandit	PG	Action	96	1977-05-26
Close Encounters of the Third Kind	PG	Science Fiction	135	1977-12-14
Saturday Night Fever	R	Music	119	1977-12-16
A Bridge Too Far	PG	Drama	175	1977-06-15
The Deep	PG	Mystery	123	1977-06-17

Texto | Factor (categorías) | Números | Fechas

titulo	mpa	genero	duracion	fecha_estreno
Star Wars	PG	Adventure	121	1977-05-25
Smokey and the Bandit	PG	Action	96	1977-05-26
Close Encounters of the Third Kind	PG	Science Fiction	135	1977-12-14
Saturday Night Fever	R	Music	119	1977-12-16
A Bridge Too Far	PG	Drama	175	1977-06-15
The Deep	PG	Mystery	123	1977-06-17

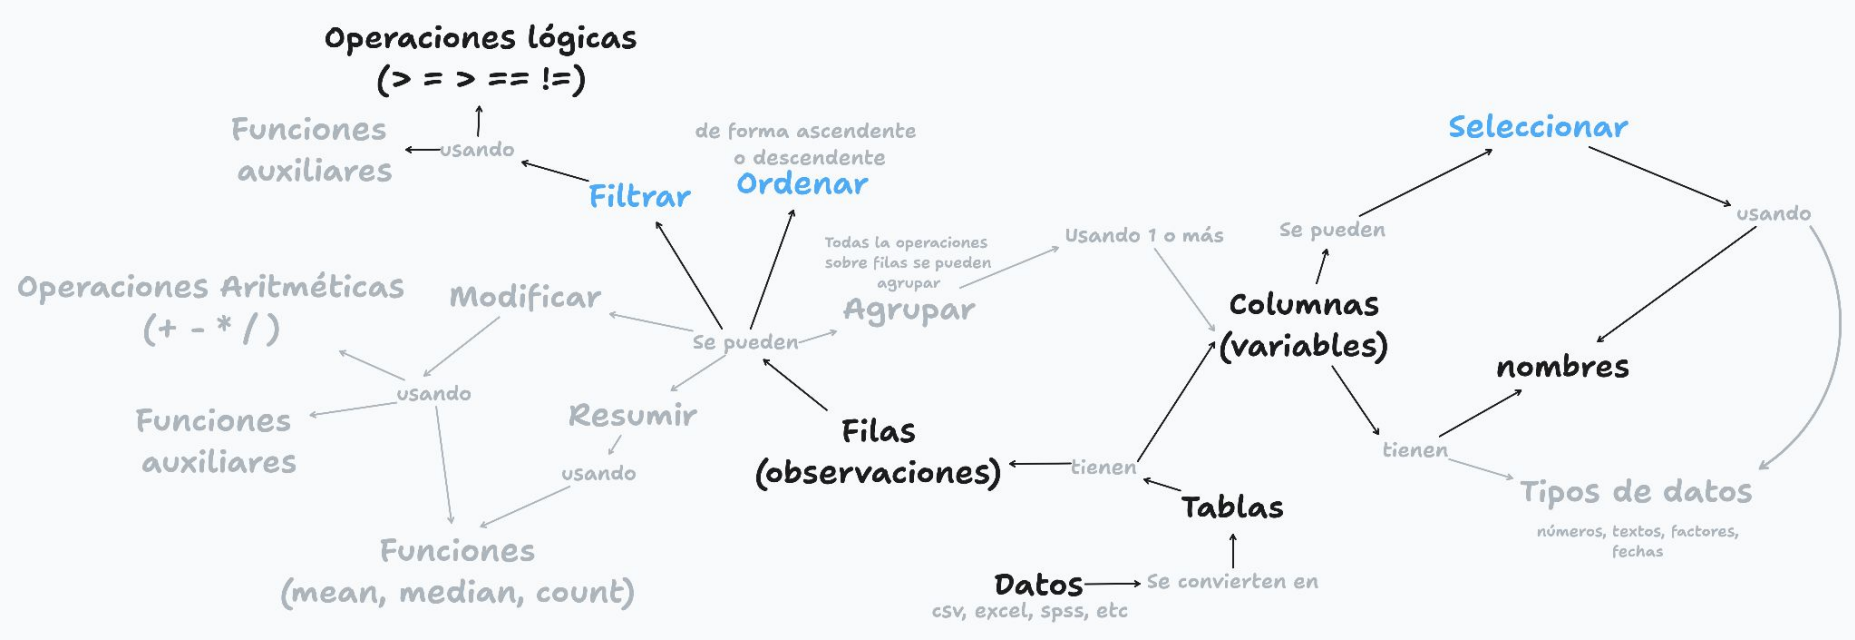
Operaciones lógicas
(> = > == !=)
Funciones
auxiliares
usando
Filtrar
de forma ascendente
o descendente
Ordenar
Seleccionar
usando
Se pueden
Todas la operaciones
sobre filas se pueden
agrupar
Usando 1 o más
Agrupar
Operaciones Aritméticas
(+ - * /)
Modificar
Se pueden
Columnas
(variables)
nombres
usando
Funciones
auxiliares
Resumir
usando
Filas
(observaciones)
tienen
tienen
Tipos de datos
números, textos, factores,
fechas
Tablas
Funciones
(mean, median, count)
Datos
csv, excel, spss, etc
Se convierten en

Filtrar

Función para filtrar datos

Condición (pregunta)

```
1 filter(clientes, edad <= 30)
```

Nombre de la tabla

```r
filter(clientes, edad <= 30)
```

Datos originales

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

Cumplen con la condición

Datos filtrados

edad	estado_civil	profesion
18	soltero	práctica
25	casado	freelance

```r
filter(clientes, edad == 32)
```

Datos originales

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

Datos filtrados

edad	estado_civil	profesion
32	soltero	NA
32	soltero	fijo

```r
filter(clientes, profesion != "fijo")
```

Datos originales

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

Datos filtrados

edad	estado_civil	profesion
35	casado	freelance
32	soltero	NA
18	soltero	práctica
25	casado	freelance

```r
filter(clientes, estado_civil != "casado")
```

Datos originales

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

Datos filtrados

?

```r
filter(clientes, estado_civil != "casado")
```

Datos originales

edad	estado_civil	profesion	
35	casado	freelance	1
50	casado	fijo	2
32	soltero	NA	3
18	soltero	práctica	4
25	casado	freelance	5
32	soltero	fijo	6

Datos filtrados

?

```r
filter(clientes, estado_civil != "casado")
```

Datos originales

edad	estado_civil	profesion	
35	casado	freelance	1
50	casado	fijo	2
32	soltero	NA	3
18	soltero	práctica	4
25	casado	freelance	5
32	soltero	fijo	6

Datos filtrados

edad	estado_civil	profesion
32	soltero	NA
18	soltero	práctica
32	soltero	fijo

Podemos tener más de un filtro

```r
filter(
    clientes,
    edad <= 30,
    estado_civil == "casado"
)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

edad	estado_civil	profesion
25	casado	freelance

Clientes con edades entre 30 y 35 años 🕵🏻

```r
filter(
    clientes,
    edad >= 30,
    edad <= 35
)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

edad	estado_civil	profesion
35	casado	freelance
32	soltero	NA
32	soltero	fijo

```r
filter(
    clientes,
    edad >= 30,
    edad <= 35
)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

```r
filter(
    clientes,
    edad >= 30,
    edad <= 35
)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
32	soltero	fijo

```r
filter(
    clientes,
    edad >= 30,
    edad <= 35
)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

edad	estado_civil	profesion
35	casado	freelance
32	soltero	NA
32	soltero	fijo

Ordenar Datos

Función para ordenar datos

Variable a usar para ordenar

```
1 arrange(clientes, edad)
```

Nombre de la tabla

```r
arrange(clientes,edad)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

edad	estado_civil	profesion
18	soltero	práctica
25	casado	freelance
32	soltero	NA
32	soltero	fijo
35	casado	freelance
50	casado	fijo

Orden descendente
(de mayor a menor)

```
1 arrange(clientes,desc(edad))
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

edad	estado_civil	profesion
50	casado	fijo
35	casado	freelance
32	soltero	NA
32	soltero	fijo
25	casado	freelance
18	soltero	práctica

```r
arrange(clientes,desc(edad))
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

edad	estado_civil	profesion
50	casado	fijo
35	casado	freelance
32	soltero	NA
32	soltero	fijo
25	casado	freelance
18	soltero	práctica

Seleccionar Columnas (variables)

Nombre de las columnas a seleccionar

Función para seleccionar columnas

```
select(clientes, edad, profesion, saldo)
```

Nombre de la tabla

```
1 select(clientes,edad, profesion, saldo)
```

edad	estado_civil	profesion	sexo	canton	saldo
35	casado	freelance	M	Heredia	1800
50	casado	fijo	F	Montes de Oca	2400
32	soltero	NA	M	Desamparados	2500
18	soltero	práctica	F	San José	3250
25	casado	freelance	F	Desamparados	1200
32	soltero	fijo	M	Curridabat	3000

```
1 select(clientes,edad, profesion, saldo)
```

edad	estado_civil	profesion	sexo	canton	saldo
35	casado	freelance	M	Heredia	1800
50	casado	fijo	F	Montes de Oca	2400
32	soltero	NA	M	Desamparados	2500
18	soltero	práctica	F	San José	3250
25	casado	freelance	F	Desamparados	1200
32	soltero	fijo	M	Curridabat	3000

```
1 select(clientes,edad, profesion, saldo)
```

edad	profesion	saldo
35	freelance	1800
50	fijo	2400
32	NA	2500
18	práctica	3250
25	freelance	1200
32	fijo	3000

Filtrar (filter)

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

Ordenar (arrange)

edad	estado_civil	profesion
50	casado	fijo
35	casado	freelance
32	soltero	NA
32	soltero	fijo
25	casado	freelance
18	soltero	práctica

Seleccionar (select)

edad	estado_civil	profesion	sexo	canton	saldo
35	casado	freelance	M	Heredia	1800
50	casado	fijo	F	Montes de Oca	2400
32	soltero	NA	M	Desamparados	2500
18	soltero	práctica	F	San José	3250
25	casado	freelance	F	Desamparados	1200
32	soltero	fijo	M	Curridabat	3000

Pipes/Tuberías

(una forma ordenada de colocar todo junto)

```
1  select(arrange(filter(clientes,edad >= 35),edad),edad, profesion, saldo)
```

```
1 select(
        arrange(
            filter(clientes,edad >= 35),
            edad
        ),
        edad, profesion, saldo
  )
```

```r
clientes |>
  filter(edad >= 35) |>
  arrange(edad) |>
  select(edad, profesion, saldo)
```

|> lo podemos colocar usando las teclas control + shift + m

```r
select(
  arrange(
    filter(
      clientes,
      edad >= 35
    ),
    edad
  )
  ,edad, profesion, saldo
)
```

```r
clientes |>
  filter(edad >= 35) |>
  arrange(edad) |>
  select(edad, profesion, saldo)
```

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
18	soltero	práctica
25	casado	freelance
32	soltero	fijo

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
32	soltero	fijo

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	estado_civil	profesion
35	casado	freelance
50	casado	fijo
32	soltero	NA
32	soltero	fijo

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	estado_civil	profesion
32	soltero	NA
32	soltero	fijo
35	casado	freelance
50	casado	fijo

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	estado_civil	profesion
32	soltero	NA
32	soltero	fijo
35	casado	freelance
50	casado	fijo

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	estado_civil	profesion
32	soltero	NA
32	soltero	fijo
35	casado	freelance
50	casado	fijo

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	profesion
32	NA
32	fijo
35	freelance
50	fijo

```r
clientes |>
  filter(edad >= 30) |>
  arrange(edad) |>
  select(edad, profesion)
```

edad	profesion
32	NA
32	fijo
35	freelance
50	fijo

Ahora de practicar

Tomemos 10 minutos y continuamos con la práctica.

Preparemos nuestro entorno de trabajo

1. **Preparar RStudio para nuestra comodidad**
2. **Crear un proyecto en RStudio**
3. **Crear una estructura de carpetas**
4. **Descargar Archivos**
5. **Listo☺️**

El cine es un negocio millonario, y aunque no podemos decir quién es el mejor director en términos artísticos, sí podemos utilizar datos para saber quién es el mejor haciendo dinero.

1. Utiliza la función **filter** para seleccionar las películas posteriores al año 2000.

2. Utiliza la función **arrange** para ordenar las películas **de la más antigua a la más moderna.**

3. Utiliza la función **select** para mostrar únicamente las **columnas de "título", "director" e "ingresos"** de las películas seleccionadas y ordenadas.

Título de la película, director y presupuesto para las 5 películas con menor presupuesto.

En qué mes se estrenaron las 5 películas con mayor calificación.

Nombre y título de la película de las 10 películas con directores mujeres con mayor popularidad.

Nombre de las 10 película anteriores a 1990 con mayor popularidad.

Director, título y votos para las 3 películas con más votantes en su calificación.

título e ingresos para las 5 películas con mayor ingreso en 2023

Extra

(Gráficos con ggplot2)

Barbie el mayor éxito en 2023

Las 5 películas con mayor ingreso (millones USD)*

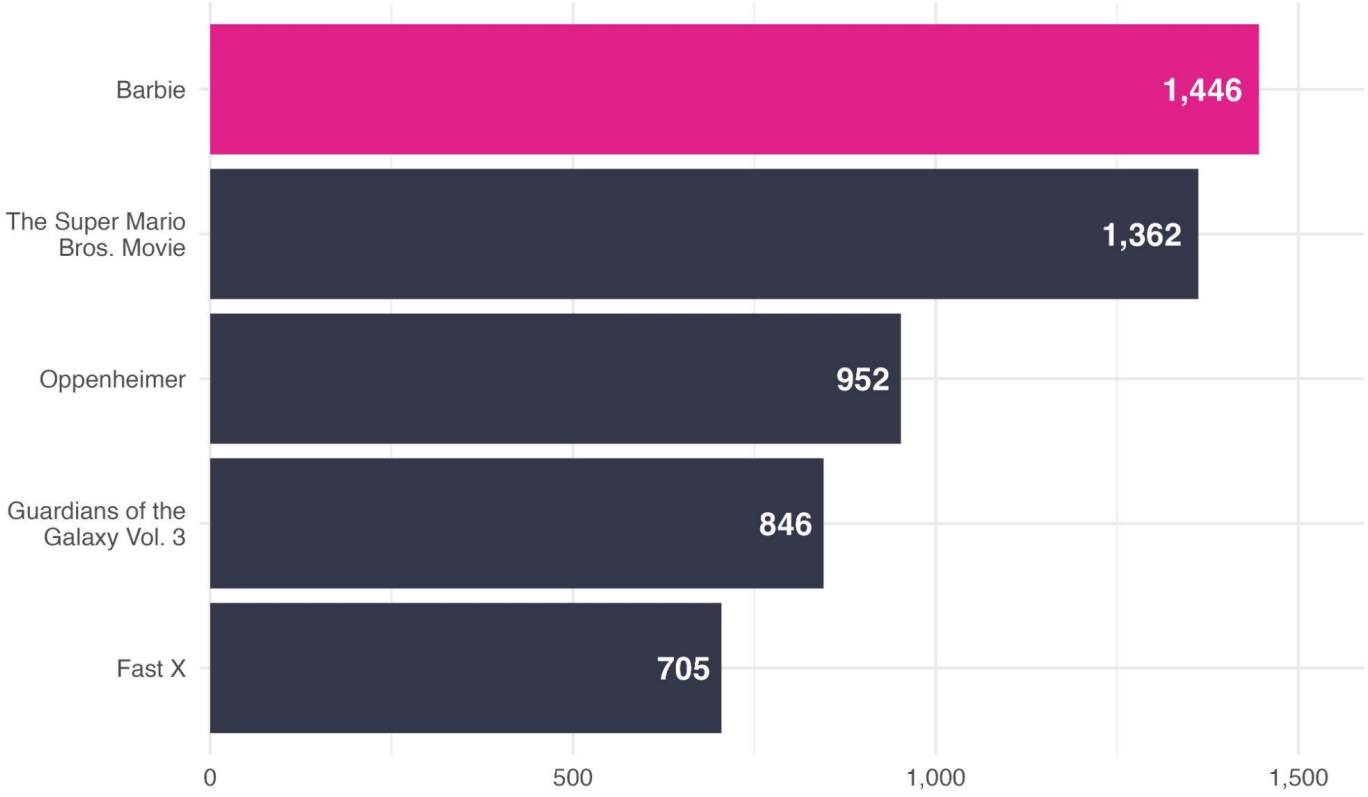

Fuente: The Movie Database (TMDB)
*Actualizado a enero 2024

El código está en *R/plot_barbie.R*, puedes jugar e intentar hacer cambios

va a haber **errores**, **muchos**, calma es parte del proceso ✨

Hadley Wickham
@hadleywickham@fosstodon.org

Periodic reminder: The only way to write good code is to write tons of shitty code first. Feeling shame about bad code stops you from getting to good code.

Mar 01, 2024 at 10:12 · · 257 · 417

aprende tidyverse